


Задача 1.

1) Схема Нейронной сети



{параметров} = 7 : $w_{111}, w_{112}, b_{111}, b_{112}, w_{211}, w_{212}, b_{211}$

2) Нахождение оптимальных параметров.

Обучающая выборка: $\{(X_1, Y_1), \dots, (X_n, Y_n)\}$

$$MSE = L(X, Y) = \frac{1}{n} \sum_{i=1}^n (Y_i - \hat{y}(X_i))^2$$

$$\hat{y}(x) = \sum_{h=1}^2 w_{2h} u_h(x) + b_2$$

$$(2.1) \quad \frac{\partial MSE}{\partial \hat{y}(X_i)} = \frac{1}{n} \cdot 2 \cdot (Y_i - \hat{y}(X_i)) \cdot (-1) = -\frac{2}{n} (Y_i - \hat{y}(X_i))$$

$$(2.2) \quad \frac{\partial \hat{y}(X_i)}{\partial w_{2h}} = u_h(X_i)$$

$$\frac{\partial \hat{y}(X_i)}{\partial b_2} = 1$$

$$\frac{\partial \hat{y}(X_i)}{\partial u_h(X)} = w_{2h}$$

$$\textcircled{2.2} \quad \frac{\partial \text{MSE}}{\partial w_{2h}} = \sum_{i=1}^n \frac{\partial \text{MSE}}{\partial \hat{y}(x_i)} \cdot \frac{\partial \hat{y}(x_i)}{\partial w_{2h}}$$

$$\frac{\partial \text{MSE}}{\partial b_2} = \sum_{i=1}^n \frac{\partial \text{MSE}}{\partial \hat{y}(x_i)} \cdot \frac{\partial \hat{y}(x_i)}{\partial b_2}$$

$$\frac{\partial \text{MSE}}{\partial u_h} = \sum_{i=1}^n \frac{\partial \text{MSE}}{\partial \hat{y}(x_i)} \cdot \frac{\partial \hat{y}(x_i)}{\partial u_h}$$

$$\textcircled{2.3} \quad \frac{\partial \sigma(x)}{\partial x} = \left(\frac{1}{1+e^{-x}} \right)' = \frac{e^{-x}}{(1+e^{-x})^2} = \frac{1+e^{-x}}{(1+e^{-x})^2} - \frac{1}{(1+e^{-x})^2} = \frac{1}{1+e^{-x}} - \left(\frac{1}{1+e^{-x}} \right)^2 =$$

$$= \sigma(x) - \sigma^2(x)$$

$$\frac{\partial u_h(x_i)}{\partial w_{1h}} = \frac{\partial (w_{1h} x_i + b_{1h})}{\partial w_{1h}} = (\sigma(w_{1h} x_i + b_{1h}) - \sigma^2(w_{1h} x_i + b_{1h})) \cdot x_i$$

$$\frac{\partial u_h(x_i)}{\partial b_{1h}} = \frac{\partial (w_{1h} x_i + b_{1h})}{\partial b_{1h}} = \sigma(w_{1h} x_i + b_{1h}) - \sigma^2(w_{1h} x_i + b_{1h})$$

Производные MSE по параметрам I слоя,

$$\frac{\partial \text{MSE}}{\partial w_{1h}} = \sum_{i=1}^n \frac{\partial \text{MSE}}{\partial u_h} \cdot \frac{\partial u_h}{\partial w_{1h}}$$

$$\frac{\partial \text{MSE}}{\partial b_{1h}} = \sum_{i=1}^n \frac{\partial \text{MSE}}{\partial u_h} \cdot \frac{\partial u_h}{\partial b_{1h}}$$

- ③ Для обновления, в случае большой выборки, можно сделать "batch" из основной выборки $\{(x_1, y_1), \dots, (x_n, y_n)\}$, и (выполняя) использовать (SGD) Стохастический Градиентный Спуск:

$$\theta_b = \theta_{b-1} - \eta \cdot \nabla \left(\frac{1}{B} \cdot \sum_{b=1}^B \text{MSE}(y_{\theta_{b-1}(x_{ib})}, y_{ib}) \right)$$

← формула из лекции

Вывод: Мы выяснили, что "метод обратного распространения"

ошибки (backpropagation) можно эффективно вычислять
градиент, и в следствие * показали возможность ~~(нахождения)~~
~~(эффектив.)~~ оптимального вычисления параметров $\hat{\theta}$.