

Метрические методы. Метрики качества

10 баллов. +2 бонусных балла

Задача 1. (1 балл)

Оценим время работы алгоритма ближайших соседей по количеству операций. Пусть X — обучающая выборка размера n , Y — тестовая выборка размера m . Размерность признакового пространства d .

Таким образом, $X \in \mathbb{R}^{n \times d}$, а $Y \in \mathbb{R}^{m \times d}$.

Квадрат евклидова расстояния между объектами x_i и y_j записывается как:

$$\rho(x_i, y_j) = \sum_{k=1}^d (x_i^k - y_j^k)^2.$$

- Определите количество операций, необходимое для подсчета всех парных расстояний в наивном случае.
- Предложите способ, с помощью которого можно уменьшить количество операций. Оцените количество операций для предложенного метода.

Решение:

- На вычисление расстояния двух точек мы тратим $3d$ операции. Так как мы считаем расстояния для $n * m$ пар точек то в итоге происходит $3nmd$
- Заметим что $\|x_i - y_j\|^2 = \|x_i\|^2 + \|y_j\|^2 - 2\langle x_i, y_j \rangle$
в таком случае посчитаем заранее нормы всех векторов X . Нормы y_j считаются за $2d$ операции (возведения в квадраты и сумма), таких векторов m . скалярное произведение считается за $2d$ операции (перемножение и сумма), таких пар всего $n * m$ итого операции = $2md + 2nmd$

Задача 2. (2 балла)

Дано n объектов, распределённых равномерно внутри d -мерного единичного шара с центром в нуле.

- Найдите выражение для медианы расстояния от начала координат до ближайшего объекта.
- Проинтерпретируйте полученный результат в терминах применимости метода ближайшего соседа в различных ситуациях.

Считайте, что метрика в задаче евклидова.

Указание: попробуйте смоделировать событие и посчитать его вероятность в терминах функций распределения.

Решение:

- Рассмотрим распределение такой случайной величины: $\min(\{\|x_i\|\}_{i=0})$ где x_i точки d -мерного шара.

$$\begin{aligned} F(x) &= P(\min(\{\|x_i\|\}_{i=0}) \leq x) = \\ &= 1 - P(\min(\{\|x_i\|\}_{i=0}) > x) \\ &= 1 - P(\|x_i\| > x)^n \\ &= 1 - (1 - P(\|x_i\| \leq x))^n \end{aligned}$$

Заметим что $P(\|x_i\| \leq x)$ вероятность попадания точки в шар радиусом x . объем шара $V_d(r) = c_d r^d$ где $c_d = \frac{\pi^{\frac{d}{2}}}{\Gamma(\frac{d}{2}+1)}$

$$P(\|x_i\| \leq x) = \frac{V_d(x)}{V_d(1)} = x^d$$

Получаем

$$F(x) = 1 - (1 - x^d)^n$$

$$F(x_{med}) = \frac{1}{2}$$

$$x_{med} = (1 - 2^{-\frac{1}{n}})^{\frac{1}{d}}$$

- при росте размерности, медиана минимального расстояния будет стремиться к 1. что значит что все почти все наши объекты будут находиться на границе шара. Становится труднее понимать что значит "близко".

Задача 3. (3 балла)

Решается задача классификации с помощью алгоритма ближайших соседей (метрика евклидова). Для тестового объекта z ближайшим соседом с расстоянием ρ_x является x , вторым ближайшим соседом с расстоянием ρ_y является объект y . Остальные объекты обучающей выборки находятся от z на достаточно большом расстоянии.

Ко всем объектам добавляется новый признак: для z и y значение признака распределено равномерно на отрезке $[-1, 1]$, для всех остальных объектов значение признака равно нулю.

- Посчитайте вероятность того, что теперь ближайшим соседом для z будет не x , а y .
- Проинтерпретируйте полученный результат в терминах применимости метода ближайших соседей.

Указание: возможно в этой задаче пригодится знание криволинейных интегралов.

Решение:

Исходные квадраты расстояний:

До объекта x : ρ_x^2

До объекта y : ρ_y^2 , причём $\rho_x < \rho_y$

После добавления нового признака:

Для z и y : значение признака равномерно на $[-1, 1]$

Для x : значение признака равно 0

пусть u — значение признака для z , v — значение признака для y

Новые квадраты расстояний:

$$\rho_{new}(z, x)^2 = \rho_x^2 + u^2$$

$$\rho_{new}(z, y)^2 = \rho_y^2 + (u - v)^2$$

Условие того, что y становится ближайшим соседом:

$$\rho_{new}(z, y) < \rho_{new}(z, x)$$

Подставляем выражения:

$$\rho_y^2 + (u - v)^2 < \rho_x^2 + u^2$$

Упрощаем:

$$\rho_y^2 + u^2 - 2uv + v^2 < \rho_x^2 + u^2$$

$$-2uv + v^2 < \rho_x^2 - \rho_y^2$$

$$2uv > v^2 + (\rho_y^2 - \rho_x^2)$$

Вводим обозначение $\delta = \rho_y^2 - \rho_x^2 > 0$:

$$2uv > v^2 + \delta$$

Признаки u и v независимы и равномерно распределены на $[-1, 1]$. Их совместная плотность вероятности:

$$f(u, v) = \frac{1}{4}, \quad (u, v) \in [-1, 1] \times [-1, 1]$$

Вероятность того, что y станет ближайшим соседом:

$$P = P(2uv > v^2 + \delta) = \frac{1}{4} \int_{2uv > v^2 + \delta} du dv$$

Оставим выкладки

$$P = \frac{I_1}{2} = \frac{1}{8} + \frac{\sqrt{1-\delta}}{4} - \frac{\delta}{8} + \frac{\delta}{4} \ln(1 - \sqrt{1-\delta})$$

Полученный результат показывает уязвимость метода к добавлению ложных (шумовых) признаков: При $\delta \rightarrow 0$ (исходные расстояния почти равны) вероятность $P \rightarrow \frac{3}{8}$. Это означает, что даже небольшой шумовой признак может с не малой вероятностью изменить ближайшего соседа.

Задача 4. (1 балл)

Докажите, что ROC-AUC случайного классификатора равен 0.5.

Решение

по определению $TPR = \frac{TP}{TP+FN}$ = доля верно предсказанных позитивных классов. Ее можно переписать вот так:

$$TPR(x) = P(f(x, w, x_0) > x | x = True)$$

где f - случайный классификатор из условия. Аналогично

$$FPR(x) = P(f(x, w, w_0) > x | x = False)$$

так как f - классифицирует случайно, то

$$P(f(x, w, x_0) > x | x = True) = P(f(x, w, x_0) > x)$$

$$P(f(x, w, x_0) > x | x = False) = P(f(x, w, x_0) > x)$$

То есть $TPR(x) = FPR(x)$

$$\begin{aligned} ROC - AUC &= \\ &= \int_1^0 TPR(x) FPR'(x) dx = \\ &= \int_1^0 TPR d(FPR) = \\ &= \int_1^0 TPR d(TPR) = \frac{1}{2} \end{aligned}$$

Что и требовалось доказать

Задача 5. (2 балла)

Пусть, $a = a(x)$ ответ алгоритма. На сколько может уменьшиться ROC-AUC при использовании функции $\min(a, 0.5)$ над оценками алгоритма?

Решение

Посмотрим TPR FPR нового алгоритма a'

$$TPR_{new}(x) = TPR(x), \quad if \quad x \leq 0.5$$

$$TPR_{new}(x) = 0, \quad if \quad x > 0.5$$

$$FPR_{new}(x) = FPR(x), \quad if \quad x \leq 0.5$$

$$FPR_{new}(x) = 0, \quad if \quad x > 0.5$$

Тогда ROC' будет состоять из отрезка соединяющего (0,0) ($TPR(0.5)$, $FPR(0.5)$) и кривой совпадающей с ROC на $t \in [0, 0.5]$

и по сути потерянная часть ROC-AUC:

$$ROC - AUC - ROC - AUC_{new} = \int_1^{0.5} TPR(x)FPR'(x)dx - \frac{1}{8}$$

Замечание

На самом деле, такое преобразование алгоритма опускает начальную часть кривой до прямой $TPR = FPR$ что для хорошего алгоритма может быть критичным, ведь на высоких порогах, он мог работать хорошо, и соответственно его ROC кривая выглядела бы более впуклой. Но после изменения алгоритма, мы бы потеряли то самое преимущество на высоких порогах

Задача 6. (3 балла)

Подробнее ознакомьтесь с материалом по ROC-AUC по ссылке и решите следующую задачу:

Пусть на ответах алгоритма m (принимающих значения от 0 до 1) задано распределение объектов класса 1 (доля объектов класса 1 в зависимости от ответа алгоритма) следующим образом:

$$\mathbb{P}(m \in [a, b] \mid y = 1) = \int_a^b p(z)dz.$$

Распределение объектов класса 0 задаётся так:

$$\mathbb{P}(m \in [a, b] \mid y = 0) = \int_a^b (2 - p(z))dz,$$

где $p(z) = -1.5z^2 + 3z$.

Найдите вероятностные оценки на величины TPR, FPR и ROC-AUC.

Решение

$$TPR(t) = P(m \geq t \mid y = 1) = \int_t^1 p(z)dz$$

$$FPR(t) = P(m \geq t \mid y = 0) = \int_t^1 (2 - p(z))dz$$

Подставляем $p(z) = -1.5z^2 + 3z$:

$$TPR(t) = \int_t^1 (-1.5z^2 + 3z)dz = 0.5t^3 - 1.5t^2 + 1$$

$$FPR(t) = \int_t^1 (1.5z^2 - 3z + 2)dz = -0.5t^3 + 1.5t^2 - 2t + 1$$

Найдём ROC-AUC:

$$ROC - AUC = \int_1^0 TPR(t)FPR'(t)dt$$

$$ROC - AUC = \int_0^1 (0.5t^3 - 1.5t^2 + 1)(1.5t^2 - 3t + 2)dt = 0.125 - 0.75 + 1.375 - 0.5 - 1.5 + 2 = 0.75$$